

Nowcasting模型研究

一、文献阅读

汇总

1. 动态因子模型

- $x_t = \mu + \Lambda f_t + \varepsilon_t$ ，观测值由状态因子+波动决定
- $f_t = A_1 f_{t-1} + \dots + A_p f_{t-p} + u_t$ ，共同因子随时间变化
- $\varepsilon_{i,t} = \alpha_i \varepsilon_{i,t-1} + e_{i,t}$ ， $e_{i,t} \sim i.i.d N(0, \sigma_i^2)$ ，波动随时间变化
- 变量
 - nowcasting为多因子DFM【月频】，观测指标分为GDP&HICP、调查数据、硬数据和市场数据，状态变量共3个，包括全局、名义和实际因子
 - real time为单因子小样本DFM【日频】，观测指标为日度收益率曲线期限溢价、周度首次申请失业金、月度非农就业人数、季度实际GDP，状态变量仅1个——实际经济活动指标
 - FCI为大规模单因子DFM【周频】，观测指标有100个，状态变量仅1个——FCI

2. 状态空间

- 观测方程 $\bar{x}_t = \bar{\mu} + Z \bar{\xi}_t$ ，看到的数据 = 状态 × 系数矩阵Z + 小噪音
- 状态转移方程 $\bar{\xi}_t = T \bar{\xi}_{t-1} + \eta_t$ ，今天的状态 = 昨天的状态 × 系数矩阵T + 小冲击

3. 混频&缺失值处理

- 混频
 - nowcasting：除GDP数据外都是月频，因此将季度GDP增长拆分为月度表示，写在观测方程里——Mariano-Murasawa (2003) 方法将其表示为
$$y_t^Q = Y_t^Q - Y_{t-3}^Q$$
$$\approx (Y_t^M + Y_{t-1}^M + Y_{t-2}^M) - (Y_{t-3}^M + Y_{t-4}^M + Y_{t-5}^M)$$
$$= y_t + 2y_{t-1} + 3y_{t-2} + 2y_{t-3} + y_{t-4}, \quad t = 3, 6, 9, \dots$$
 - real time&FCI【更高级】：存量变量和流量变量通过观测方程/状态方程中的矩阵来实现混频
 - Real time：在观测方程中构建低频观测变量和高频状态的关系

- 存量变量表达式【某一时点观察到的值】

$$\tilde{y}_t^i = \begin{cases} c_i^* + \beta_i x_t + \delta_{i1}^* t + \cdots + \gamma_{i1} \tilde{y}_{t-D_i}^i + \cdots + u_t^{*i} & \text{if stock observed} \\ NA & \text{otherwise.} \end{cases}$$

- 流量变量表达式【一段时间内的累计量】

$$\tilde{y}_t^i = \begin{cases} c_i^* + \beta_i \sum_{j=0}^{D_i-1} x_{t-j} + \delta_{i1}^* t + \cdots + \gamma_{i1} \tilde{y}_{t-D_i}^i + \cdots + u_t^{*i} & \text{if flow observed} \\ NA & \text{otherwise.} \end{cases}$$

- FCI: 在状态矩阵中增加累加器Harvey accumulator, 借助状态变量 S_t 自行递推

- 求和累加器 $S_t = s_t S_{t-1} + \alpha_t$, $s_t = \begin{cases} 0 & \text{如果是新的一期开始} \\ 1 & \text{否则} \end{cases}$,

$$\alpha_{t+1} = \rho \alpha_t + R \eta_t \text{ 服从AR(1), } \begin{bmatrix} \alpha_t \\ S_t \end{bmatrix} = \begin{bmatrix} \rho & 0 \\ \rho & s_t \end{bmatrix} \begin{bmatrix} \alpha_{t-1} \\ S_{t-1} \end{bmatrix} + \begin{bmatrix} R \\ R \end{bmatrix} \eta_{t-1}$$

- 平均累加器 $M_t = \frac{(m_t - 1)M_{t-1} + \alpha_t}{m_t}$, $m_t = \begin{cases} 1 & t \text{ 为当月第1周} \\ 2 & t \text{ 为当月第2周} \\ \text{以此类推} \end{cases}$,

$$\alpha_{t+1} = \rho \alpha_t + R \eta_t \text{ 服从AR(1), } \begin{bmatrix} \alpha_t \\ M_t \end{bmatrix} = \begin{bmatrix} \rho & 0 \\ \frac{\rho}{m_t} & \frac{m_t-1}{m_t} \end{bmatrix} \begin{bmatrix} \alpha_{t-1} \\ M_{t-1} \end{bmatrix} + \begin{bmatrix} R \\ \frac{R}{m_t} \end{bmatrix} \eta_{t-1}$$

- 缺失值处理: 构建矩阵表明数据是否存在, Kalman Filter 自动处理

- nowcasting将jagged edge也看作缺失值

- real time在更新时, 若当期部分数据可观测, 则将观测变量和矩阵缩减

$y_t^* = Z_t^* \alpha_t + \Gamma_t^* w_t + \varepsilon_t^*$; 若当期所有数据缺失, 则整个 y_t 不可观测, 跳过更新步骤, 只做预测

- FCI引入矩阵 W_t 表示“这一期到底哪些数据是有的”

- $y_t^* = W_t y_t$ 表示将 y_t 中缺失的数据行删掉, 只留下能观测到的
- $Z^* = W_t Z$ 表示模型里的系数矩阵也要跟着删掉对应行
- $H^* = W_t H W_t'$ 表示误差的方差矩阵也只保留观测到的部分

4. 模型

- Nowcasting: E步卡尔曼平滑, M步最大似然

- 模型构建: 月度数据PCA计算三个初始因子→因子带回得到初始参数→E步骤: 输入参数, 卡尔曼平滑估计出状态变量的条件期望→M步骤: 把E步补齐的状态变量当成真的已知数据, 做一次标准的最大似然, 更新所有参数→重复EM得到最终参数值

- 数据更新：根据估计好的参数，估计出因子和缺失值→计算目前信息对GDP的预测&各指标对应权重b→新数据发布前，计算旧数据对所有指标的预测值→新数据发布后，新闻=新数据 - 模型原本预测值，预测的变动 = 每条新闻 × 权重b加总，GDP新预测=GDP旧预测+预测的变动

◦ real time: MLE

- 信号提取：对于每一组参数，用状态的无条件均值和方差初始化状态→数据到达前，根据上一期状态预测当前状态和方差→数据到达后，看数据计算创新项和创新方差，并修正状态和方差→将更新后的状态作为下一期预测的起点，循环执行更新+预测
- 估计参数：对每一组参数，根据上述流程计算出对应的对数似然函数

$$\log L = -\frac{1}{2} \sum_{t=1}^T [N_t \log 2\pi + (\log |F_t| + v_t' F_t^{-1} v_t)]$$
，选择使得log L最大的参数

【BFGS 拟牛顿法】

- 参数初始值计算：只用日度+月度**存量**变量，快速算出参数和经济景气因子；用第一步算出来的景气因子，当做已知值，去回归周度、季度这些**流量**变量。回归得到的系数，直接当做流量方程参数的初始值
- 最终状态估计：固定最优参数后，代回Kalman smoother，得到经济状态

◦ FCI: E步卡尔曼, M步OLS

- EM算法：输入当前参数（Z, H, T, Q 等）→使用Kalman filter + Kalman smoother→输出隐藏因子估计值、协方差矩阵→输入E步得到的因子估计→使用OLS→输出更新后的系统参数（Z, H, T, Q 等）

- 收敛：重复上述直到 $\log L = -\frac{1}{2} \sum_{t=1}^T (\log |F_t^*| + v_t' F_t^{*-1} v_t)$ 基本不在变化，即 $\left| \frac{\log L(k) - \log L(k-1)}{(\log L(k) + \log L(k-1))/2} \right| < 10^{-6}$ 时停止

5. 结论

- nowcasting：GDP信息作用具有阶段性【季度前期调查数据主导，后期硬数据主导】；预测变化可以被“解释”
- real time：预测有效，提供一致指标；周频就足够提升因子精度，日频边际贡献很小
- FCI：不同指标对FCI波动解释比例；跨时期对比分析（1984年后市场整体波动率下行）；小样本指标容易受波动影响

6. 其他

- Markov-switching马尔可夫链
 - 将连续的FCI因子映射为正常/危机等离散分类
 - 最终输出每一时刻“属于哪个状态的概率”，以及每种状态中数值的均值和波动

■ 用于检验生成的GDP是否有效

○ ROC

- 从分数中得到最优阈值
- 用历史真实状态定义标签后，可根据每个阈值计算：TPR（召回/真正率）、FPR（误报率）
- 法1：通过TPR-FPR画出ROC曲线，AUC 是 ROC 曲线下面积，AUC 越接近 1表明指标越能区分危机和非危机
- 法2：使得社会计划者效用函数最大，即 $\frac{d ROC(r)}{dr} = \frac{U_{00} - U_{10}}{U_{11} - U_{01}} \cdot \frac{1 - \pi}{\pi}$ ，通过定义不同情况下的权重计算出最优阈值
- 可根据对误报还是

7. 总结-融合模型数据&框架

○ 数据

- 大变量样本周频更适合
- 时间范围
- 分为宏观基本面、货币市场、权益市场和银行系统
 - 宏观基本面

	变量名称	
景气	制造业PMI	当月值；月
	非制造业PMI	当月值；月
生产端	规模以上工业增加值	同比；月
	全社会用电量	月
需求端	社会消费品零售总额	当月值；月
	固定资产投资	同比；月
价格	居民消费价格指数	累计值；月
	工业生产者出厂价格指数	同比；月
就业	全国城镇调查失业率	月
经济总量	GDP	季度

- 货币市场

	变量名称
短端资金面	DR007利率
	Shibor 3个月利率
	中期借贷便利利率
	逆回购利率
	同业存单利率
	银行间回购利率
	资金利差（Shibor-DR007）
利率债	1年期国债收益率
	10年期国债收益率
期限利差	收益率曲线斜率（10Y-1Y）
	收益率曲线斜率（10Y-DR007）

- 权益市场

	变量名称
价格	沪深300指数
	中证500指数
	创业板指数
交易情绪	股票成交额
	股票换手率
	融资融券余额
	陆股通
	港股通
估值	全A 市盈率
	全A 市净率
风险	股债收益差

- 银行系统

	变量名称
总量	社会融资规模
投放	新增人民币贷款
结构	企业中长期贷款
	票据融资
货币	M2货币供应量
信用风险	信用利差（AAA-国债）
	信用利差（AA-AAA）

- step1: DFM+状态空间表示
 - 预测目标是哪个因子——GDP
 - 状态因子用几个：全局&名义&实际，全局和名义因子影响名义变量，全局和实际因子影响实际变量
 - 假设
 - 线性状态空间
 - 高维变量可以被少数潜在因子解释，变量之间的相关性来自共同因子
 - 观测变量仅由因子和波动表示，因子和波动为AR(1)
 - 模型参数不随时间变化，仅有状态转移矩阵在技术上“随时间变化”因为其代表不同月份/季度长度不同
- step2: 混频用FCI accumulator处理
 - 假设高频变量是月度变量的线性组合
- step3: 缺失值用FCI矩阵
- step4: 参数估计用EM方法【参考 [wp2010-07-pdf.pdf](#) P7、P22-24】
 - PCA得到初始因子值和参数值
 - E步：卡尔曼得到因子值
 - M步：最大似然估计/OLS得到因子值
 - 循环E&M步，使得最大似然函数的变化值 $< \left| \frac{\log L(k) - \log L(k-1)}{(\log L(k) + \log L(k-1))/2} \right| < 10^{-6}$
- step5: 用卡尔曼实时更新——nowcasting
 - 卡尔曼模型输入：长面板结构，date-var-value；观测矩阵和状态转移矩阵
 - 计算状态因子
 - 新观测数据到来之前计算状态因子的预测值和方差
 - 新观测数据到来之后：计算新闻值→更新新方差→更新状态因子或变量

先计算“新闻”:

$$v_t = y_t - \hat{y}_{t|t-1}$$

然后更新:

$$\hat{\alpha}_{t|t} = \hat{\alpha}_{t|t-1} + K_t v_t$$

👉 总结:

$$FCI_{\text{新}} = FCI_{\text{预测}} + (\text{新闻} \times \text{权重})$$

- 计算观测变量：通过观测方程和已有状态因子
- 卡尔曼模型输出：各期潜在状态估计、观测因子估计、卡尔曼增益（变量的影响权重）
- 假设：数据更新中的意外部分能够对预测进行修正
- step6：模型有效性检验（FCI）
 - 模型预测 vs wind预测 vs 实际值
 - Markov-switching马尔可夫链检验

[nowcasting oxford handbook chapter.pdf](#) [nowcasting working paper.pdf](#)

Marta BańBura, Domenico Giannone, and Lucrezia Reichlin (2011)

1. 核心概念

- Nowcasting **P2**
 - 定义：利用与目标变量相关但采集频率更高（通常按月统计）且发布时间更及时的数据信息，来预测采集频率较低（通常按季度统计）且发布存在显著滞后性的关键宏观经济变量。
 - 核心优势：在数据发布存在异步性且存在不同发布时间差的环境下，仍能整合最新信息。
- ragged/jagged edge：数据发布时间不一样，末尾有的有数据、有的没有，看起来像锯齿一样不齐
- News新闻：即公布数据超出预期的部分，=实际发布值－模型预测值
- 混合频率：月频数据+季频数据

2. 研究问题

- 利用月频或更高频数据来即时预测季频GDP
- 解释预测值的变化由哪个变量引起，贡献了多少

3. 模型框架

- 动态因子模型
 - $x_t = \mu + \Lambda f_t + \varepsilon_t$
 - 描述观测变量由global、nominal和real这三个共同因子影响

- global和nominal影响nominal变量，global和real影响real变量
- $f_t = A_1 f_{t-1} + \dots + A_p f_{t-p} + u_t$
 - 三个因子服从VAR (p) 过程，后文规定p=1
- $\varepsilon_{i,t} = \alpha_i \varepsilon_{i,t-1} + e_{i,t}$, $e_{i,t} \sim i.i.d N(0, \sigma_i^2)$
 - error服从AR (1) 动态
- GDP混频处理方式
 - 设月度GDP变量，构建月度GDP和已知的季度GDP关系式

$$y_t^Q = y_t + 2y_{t-1} + 3y_{t-2} + 2y_{t-3} + y_{t-4}, \quad t = 3, 6, 9, \dots$$
 - 月度GDP变量也由上述动态因子模型表示
- 将动态因子模型写成状态空间形式
 - 状态向量 ξ_t 包括共同因子及其滞后项、变量error及其滞后项、GDP error及其滞后项
 - 观测方程 $\bar{x}_t = \bar{\mu} + Z \bar{\xi}_t$ 描述能观测的变量与不可观测的状态,Z为动态因子模型表达式中的参数矩阵
 - 状态方程 $\bar{\xi}_t = T \bar{\xi}_{t-1} + \eta_t$ 描述状态随时间的演变，T为因子VAR过程、error AR (1) 过程等系数矩阵

4. 数据设计

- 目标变量：GDP季度环比增长率【季频】、HICP年度通胀率【月频】
- 观测变量（基准：26项；细分：更多行业信息）&目标变量

分类	含义	完整变量	
实际块 (Real variables)	软数据 (Soft data) -调查	PMI (制造业)、PMI (服务业业务活动)、消费者信心指数、工业信心指数、零售信心指数、服务业信心指数	发布最早，反映具有领先性
实际块 (Real variables)	硬数据 (Hard data)	工业生产 (总工业、制造业)、零售销售 (不含汽车)、新乘用车注册、制造业新订单、欧元区外出口、失业率、就业指数	发布滞后，但与具有高精度
名义块 (Nominal variables)	名义信息 (价格/货币)	HICP (通胀)、PPI、消费者价格预期、企业售价预期、M3货币供应量、贷款指数	反映价格与货币
金融与市场块 (Financial & Commodity)	股票市场、利率、汇率、商品	Euro Stoxx股票指数、Euribor利率、欧元名义有效汇率、原材料价格 (不含能源)、原油价格	高频、对市场预冲击
目标变量 (Target variables)	被预测变量	GDP (季度)、HICP (通胀)	作为预测对象，闻 (news) ”

- 数据结构：混频、ragged edge
- ①混频处理：统一为月频

- 更高频数据→月底汇总为月均值
- 商品价格→取每月前15天平均值，月中即可获得
- GDP→Mariano-Murasawa近似将季度GDP转化为伪月度序列
- ②平稳化处理：对数差分得到增长率
- ③ragged edge构造：根据各变量的典型发布延迟确定月中、月末两个时点，统计每个变量有多少个月份的数据缺失
- ④构建实时信息集：在每个预测时点构建当时已发布的数据
- ⑤缺失值处理：将所有月度变量（包括伪月度GDP）按时间索引对齐，形成面板矩阵，缺失值在面板中为空

5. 实现方法

- 参数估计：EM算法
 - step1——参数初始化：用月度观测变量主成分分析，取3个主成分为因子（全局、实际、名义），得到初始因子，带回计算出其他参数
 - step2——E：利用初始参数，卡尔曼平滑估计状态变量的条件期望
 - step3——M：把E步得到的状态变量当成已知数据，做最大似然，更新所有参数
 - step4——迭代：不断迭代E→M→E，直到参数变化小于很小的阈值
- nowcasting模型构建
 - step1：卡尔曼滤波做nowcast，根据估计好的参数得到因子值和缺失值，还得到变量的新闻权重b
 - step2：当每一次数据发布时
 - 预测：基于数据发布前的状态估计，得到本期所有变量的预测值
 - 更新：计算**新闻**=实际发布值-发布前预测值，再预测变化=**所有新闻的线性组合**

6. 实验结果

- 从2008年7月至2009年1月，持续更新对2008Q4 GDP和2008M12 HICP的估计→预测表现&新闻拆解

	预测值变化趋势	预测值变化拆解
GDP	• 在预测早期（7-9月），GDP 预测基本平稳：对“当前季度以外”的预测能力较弱 • 第一次明显下调出现在10月调查数据发布后：当期数据带来较大预测变化	• real调查数据在季度初期最早反映经济转弱 • 数据陆续发布，real硬数据新闻贡献逐渐增大 • nominal数据贡献有限

	• 季度末及之后预测逐渐收敛，变化幅度减小：信息趋于完整后，判断也趋于稳定	
HICP	• 最大降幅出现在月中：HICP数据自身月中发布	• HICP自身：每次HICP数据发布（月中）都会产生较大的新闻贡献 • 商品价格也是最大的新闻来源 • real调查/硬数据和名义变量都影响较小

- 2000年至2007年伪实时预测的RMSFE→预测准确度
 - 伪实时预测：在过去的时间点只使用当时“可获得的数据”，每次重新估计模型参数，得到预测后计算RMSFE
 - 对照模型
 - GDP：对数GDP水平的带漂移项的随机游走——GDP有长期增长趋势
 - HICP：年度通胀率的无漂移随机游走——通胀没有稳定趋势
 - 结论
 - 模型对比：动态因子模型相较于对照模型主要优势体现在当前季度的预测，在远期预测上优势较弱
 - 不确定性变化：随着信息逐步增加，预测不确定性（RMSFE）显著下降 → 从最早预测到最终预测RMSFE下降约50%
- 基准数据集vs更大数据集→预测稳定性
 - 结论：增加变量数量并未显著提升预测精度，但模型稳定性未下降

7. 文献对比与创新

方面	文献	文献方法特点&局限性	本文改进
不可观测因子	Evans (2005)	假设 GDP 是唯一不可观测的因子	用 统一状态空间 描述目标变量与预测变量联合动态；使用更一般的因子结构（全球、名义、实际因子）
混频处理-月度数据汇总成季度- Bridge Equations	Trehan (1989) and Parigi and Schlitzer (1995), Parigi and Golinelli (2007), and Runstler and Sédillot (2003), Diron (2008), Kitchen and Monaco (2003)	将月度变量 等权重 转化为季度再回归，缺失的月度数据另外建小模型填补。 • 无法预测输入变量→无法分解新闻 • 无法解释各变量对预测值的影响	预测所有指标→计算出新闻→计算出新闻如何影响预测值

混频处理-月度数据汇总成季度-MIDAS法	Ghysels et al.(2004); Clements&Galvão(2008); Marcellino&Schumacher (2010)	不做频率转换，而是直接保留月度数据原来的样子，用多项式对每个月数据赋予 不同权重，不用人为规定。 - 参数不是固定的，随预测季节、缺失数据而变化→无法统一解释含义 - 不能预测其他指标→无法分解新闻	同上 参数一次估计完
新闻分解-用调查数据改进	Ghysels & Wright (2009)	用调查数据作为“预期”， 新闻 = 实际发布值 - 调查预期值，用辅助回归把“调查新闻”和 GDP 预测的修订联系起来 调查数据是外生的，不由模型产生	不需要依赖调查数据，模型自己产生预测值，新闻和权重都来自同一个模型
缺失值补充-PCA+EM方法	Stock & Watson (2002b)	使用PCA+EM，可处理混频和缺失数据 - 只看不同变量在同一横截面的关系 - 忽略变量自身的时间依赖	变量在同一横截面的关系用因子衡量 因子用VAR模型→每个因子用自己的滞后项解释【对角矩阵】 特异项用AR模型→每个变量误差项用自己的滞后项解释
缺失值补充-因子VAR方法	Schumacher&Breitung (2008)	使用因子本身的VAR模型来填补缺失值 - 额外建一个辅助模型来预测缺失值 - 仍忽略变量自身的时间依赖	将VAR纳入状态空间内统一处理
混频处理-季度GDP月度拆分-近似法	Mariano & Murasawa (2003) Angelini et al. (2008) Banbura & Modugno (2010)	把季度GDP用 增长率近似 拆成月度数据 拆出来的月度GDP加总不等于真实季度GDP	本文沿用这个近似算法，将其放入完整动态因子模型
混频处理-季度GDP月度拆分-精确加总法	Mitchell et al. (2005) Proietti (2008)	采用其他技术，确保估计出来的月度 GDP 水平值加起来正好等于观测到的季度 GDP 总值	\

经济活动同步指标 【实时衡量经济状况】	Stock 和 Watson (1989)- 开山之作	\	\
	Altissimo et al. 2001, 2006-欧元区的同步指标	为了处理末端缺失数据，直接 把变量时间平移 。比如把工业生产的t-1当成t用，强行对齐 导致模型结构变化，非时不变【数据发布后，模型对齐方式又要变】	不改日期、不平移 模型从头到尾不变
	Chicago FED, 2001-美国的同步指标	用辅助模型来预测缺失的观测值	预测值由模型本身产生
	Aruoba, Diebold, Scotti (2009) -包括月度数据	\	\

8. 未来研究方向

- 未解决问题
 - 未考虑数据修订过程：同一个指标随着统计数据越来越全，会不断更新，从初值到修正值，再到最终值
 - 没有纳入频率高于月度的数据：文章将部分变量转化为月度频率，并视为在获得整个月的信息时才发布
 - 没有考虑参数不稳定性和随机波动性：文章参数估计一次就不变；文章假设经济波动恒定

real time measurement of business conditions.pdf

Aruoba, S. B., Diebold, F. X., & Scotti, C. (2009).

1. 核心概念

- 实时经济状态：经济状态不是直接观测的，而是“潜变量（latent variable）”
- 变量
 - 存量变量：某一时点值
 - 流量变量：一段时间累计

2. 研究问题

- 如何“实时”衡量经济状态？-高频+多变量 → 实时指标
- 如何整合不同频率数据？-状态空间 + Kalman Filter
- 高频数据是否真的有价值？-加入高频数据是否提高测度精度

3. 模型框架&研究思路

- 按日频建模的，因为即使最高有效信息只到周频，也仍然需要日频基础框架来处理“每月有多少天、每季有多少天”的变化
- 状态方程 $x_t = \rho_1 x_{t-1} + \rho_2 x_{t-2} + \dots + \rho_p x_{t-p} + e_t$ ， x_t 为日频变化的潜在经济状态
- 观测方程 $y_t^i = c_i + \beta_i x_t + \delta_{i1} w_t^1 + \dots + \delta_{ik} w_t^k + \gamma_{i1} y_{t-D_i}^i + \dots + \gamma_{in} y_{t-nD_i}^i + u_t^i$
 - 表示每个观测变量都是状态变量的带噪声线性映射
 - y_t^i 为观测变量，如GDP、就业等
 - w_t 为外生变量，比如趋势
 - y_{t-D_i} 为滞后项，用于捕捉月度、季度惯性
 - u_t^i 为噪声
- 数据处理
 - 存量变量：某一时点观察到的值→其他日期为缺失
 - 观测日的观测方程为 $\tilde{y}_t^i = c_i^* + \beta_i x_t + \delta_{i1}^* t + \dots + \gamma_{i1} \tilde{y}_{t-D_i}^i + \dots + u_t^{*i}$
 - 非观测日的观测方程为missing
 - 流量变量：一段时间内的累计量→对过去 D_i 天加总
 - 观测日的观测方程为 $\tilde{y}_t^i = c_i^* + \beta_i \sum_{j=0}^{D_i-1} x_{t-j} + \delta_{i1}^* t + \dots + \gamma_{i1} \tilde{y}_{t-D_i}^i + \dots + u_t^{*i}$
 - 非观测日的观测方程为missing
 - 依此用观测方程描述日度潜在状态加总/观察映射到已有数据频率
 - weekly claims、monthly employment、quarterly GDP 在其观测频率下也带 AR(1) 持久性，因此相应滞后值进入 w_t ；term spread 的自相关则通过观测误差项的 AR(1) 处理，而不是放入 w_t
- 状态空间+Kalman Filter
 - 状态空间
 - 观测方程 $y_t = Z_t \alpha_t + \Gamma_t w_t + \varepsilon_t$
 - Z 的系数参考存量变量和流量变量的观测方程，属于时变矩阵（本月/本季天数不同）
 - 状态方程 $\alpha_{t+1} = T \alpha_t + R \eta_t$
 - 注意flow变量的观测方程中 α_t 包括了多期状态变量，因此状态方程中 α_t 也要包含多期，比如如果是季度则要包含91期， T 为伴随移位矩阵，使得 α_t 框选日期下移得到 α_{t+1}
 - 构造缺失值矩阵

- 输入每天4个变量的理论观测值位置
- 输出每天的观测掩码和缩减版缩减观测系统生成函数
- 初始化参数
 - step1: 只用日度 + 月度**存量**变量，快速算出参数和经济景气因子
 - step2: 用第一步算出来的景气因子，当做已知值，去回归周度、季度这些**流量**变量。回归得到的系数，直接当做流量方程参数的初始值
- 状态初始化
 - 在初始参数下，用状态的无条件均值和方差初始化状态变量 a_t 和方差 P_t ，作为卡尔曼滤波起点
- 卡尔曼filter递推
 - 数据到达前，根据上一期状态预测当前状态 $\alpha_t = E(\alpha_t | Y_{t-1}) = T a_{t-1|t-1}$ 和方差 $P_t = \text{Var}(\alpha_t | Y_{t-1}) = T P_{t-1|t-1} T' + R Q R'$
 - 数据到达时
 - 若有完整数据，修正状态 $a_{t|t} = a_t + P_t Z_t' F_t^{-1} v_t$ 和方差 $P_{t|t} = P_t - P_t Z_t' F_t^{-1} Z_t P_t$
 - 若有部分数据，则将观测变量和矩阵缩减 $y_t^* = Z_t^* \alpha_t + \Gamma_t^* w_t + \varepsilon_t^*$
 - 若当期所有数据缺失，则跳过更新步骤，只做下一期预测
 - 递推：重复数据到达前预测+数据到达后更新
 - 目标：迭代使得卡尔曼滤波构造的对数似然函数

$$\log L = -\frac{1}{2} \sum_{t=1}^T [N_t \log 2\pi + \log |F_t| + v_t' F_t^{-1} v_t] \text{ 最大}$$
 - 估计方法：BFGS 拟牛顿法

4. 数据设计

- 数据
 - 日度：收益率曲线期限溢价（存量）=美国10年期国债收益率与3个月期国债收益率的差值→金融变量、强周期性
 - 周度：首次申请失业金（流量，加总到周六）→劳动市场、强周期性
 - 月度：非农就业人数（存量，月末）→劳动市场、强周期性
 - 季度：实际 GDP（流量，季度末）→真实经济活动
- 数据预处理
 - 去趋势→零均值
 - 假设潜在经济状态 x_t 和各观测变量均在自身观测频率下AR（1）

5. 结论

- 构建了实时经济指标：指标与 NBER recession 高度一致，还更早识别拐点
- GEI 明显优于 GE，而 $GEIS \approx GEI \rightarrow$ 高频（周频）数据显著提升效果，日频数据边际提升有限
- 模拟验证上，GEI 与真实因子相关性和 MSE 相较于 GE 表现较好 $\rightarrow$ 高频数据显著提高因子提取精度
- 不足
 - 尝试纳入新闻头条等**定性信息**的指标
 - 引入**非线性**区制转移动态
 - 对比评估“小数据”方法（如本文）与“大数据”方法的效果与结论——数据并非越多越好
 - 完整实时分析，应该纳入“数据修订过程”

wp2010-07-pdf.pdf Gathering Insights on the Forest from the Trees: A New Metric for Financial Conditions

1. 核心概念

- 金融条件指数（FCI）：用一个“潜在因子”来综合刻画金融体系整体状态
- Harvey Accumulator：解决混合频率数据（周 / 月 / 季）和流量 vs 存量变量
- EM算法
 - E步：用卡尔曼滤波 + 平滑 $\rightarrow$ 估计隐变量
 - M步：OLS更新参数
- 金融危机识别方法
 - Markov-switching根据FCI将状态划分为正常、危机和过渡，依此验证FCI能够识别危机
 - ROC方法计算FCI划分危机的门槛

2. 研究问题

- 如何用大量金融变量构造一个统一指标
- 如何让指数具有政策意义 $\rightarrow$ 阈值在哪里

3. 模型框架&研究思路

- 构建动态因子模型：多变量用FCI表示，FCI自身满足AR (1)
- 混频处理
 - 变量分类

变量类型	通俗含义	是否需要 Harvey 累加	例子
存量 Stock	某一时间点的快照数值	✗ 不需要	月末利率、时点资产价格
流量 Flow	一段时期内累计发生总和/均值	✓ 必须累加	月度新增信贷、季度金融波动均值
差分存量	对存量做差分处理	✓ 等价流量处理	月度环比存款变化

类型	本质	是否累加	例子
求和型	总量	✓ 累加	贷款总额=F1+F2+F3+F4
均值型	平均水平	✓ 累加+平均	平均利差=(F1+F2+F3+F4)/4
一阶差分	变化量	✓ 等价于累加	月度环比存款变化=本月存款 - 上月存款 =周1变化+周2变化+周3变化+周4变化

累加器分类

- 求和累加器 $S_t = s_t S_{t-1} + \alpha_t$, $s_t = \begin{cases} 0 & \text{如果是新的一期开始} \\ 1 & \text{否则} \end{cases}$

将累加器融入状态方程: $\begin{bmatrix} \alpha_t \\ S_t \end{bmatrix} = \begin{bmatrix} \rho & 0 \\ \rho & s_t \end{bmatrix} \begin{bmatrix} \alpha_{t-1} \\ S_{t-1} \end{bmatrix} + \begin{bmatrix} R \\ R \end{bmatrix} \eta_{t-1}$

- 平均累加器 $M_t = \frac{(m_t - 1)M_{t-1} + \alpha_t}{m_t}$, $m_t = \begin{cases} 1 & t \text{ 为当月第1周} \\ 2 & t \text{ 为当月第2周} \\ \text{以此类推} \end{cases}$

将累加器融入状态方程: $\begin{bmatrix} \alpha_t \\ M_t \end{bmatrix} = \begin{bmatrix} \rho & 0 \\ \frac{\rho}{m_t} & \frac{m_t-1}{m_t} \end{bmatrix} \begin{bmatrix} \alpha_{t-1} \\ M_{t-1} \end{bmatrix} + \begin{bmatrix} R \\ \frac{R}{m_t} \end{bmatrix} \eta_{t-1}$

缺失值处理

- 引入矩阵 W_t 表示 “这一期到底哪些数据是有的”

EM算法

- E步: 输入当前参数 (Z, H, T, Q 等) → 使用 Kalman filter + Kalman smoother → 输出隐藏因子估计值、协方差矩阵
- M步: 输入E步得到的因子估计 → 使用 OLS → 输出更新后的系统参数 (Z, H, T, Q 等)

- 收敛判断: $\log L = -\frac{1}{2} \sum_{t=1}^T (\log |F_t^*| + v_t' F_t^{*-1} v_t)$, 有

$$\left| \frac{\log L(k) - \log L(k-1)}{(\log L(k) + \log L(k-1))/2} \right| < 10^{-6} \text{ 时停止迭代}$$

识别金融危机

- 用历史事件 (5次金融危机) 来划分出危机样本

◦ Markov-switching——验证FCCI能识别金融危机识别方法

■ 将市场分为三种状态

状态	均值 μ	波动 σ	经济解释
State 1	低	低	正常稳定
State 2	高	高	金融危机
State 3	低	高	不稳定/过渡

■ 发现

- 状态2（高均值、高波动）与历史危机高度对应，模型成功识别危机时期
- 2002–2007年FCCI低但状态3概率高，表明存在“长期低风险表象下的潜在脆弱性”

◦ ROC分析

■ 命中率 $TP(c) = P(F_t \geq c \mid S_t = 1)$ ，误报率 $FP(c) = P(F_t \geq c \mid S_t = 0)$

■ 画出ROC曲线，横轴为FP，纵轴为TP，每个点对应一个阈值

■ 构造社会计划者效用函数

- $U = U_{11}ROC(r)\pi + U_{01}(1 - ROC(r))\pi + U_{10}r(1 - \pi) + U_{00}(1 - r)(1 - \pi)$
- 要使得U最大，有 $\frac{dROC(r)}{dr} = \frac{U_{00} - U_{10}}{U_{11} - U_{01}} \cdot \frac{1 - \pi}{\pi}$
- 不同政策（均衡/重在识别危机/重在不错判危机）下的最优解不同

4. 结论

- 不同指标对指数有不同方向和程度的贡献
- 与其他指数对比
- 跨时期对比分析：二者重叠区间的差异主要体现指数绝对水平高低，波动走势高度一致；绝大多数金融变量在两组指数中的权重差异极小；三大类指标之间权重有所转移
- 不同指标维度间指数对比：小样本指标存在明显问题，大样本指标更加稳定