

中观行业景气度：Nowcasting 初探

华泰研究

2021年9月26日 | 中国内地

深度研究

研究员 林晓明
SAC No. S0570516010001 linxiaoming@htsc.com
SFC No. BPY421 +86-755-82080134
联系人 徐特, PhD
SAC No. S0570121050032 xute@htsc.com

相关研究

- 1 《金工：行业配置策略：景气度视角》
2020.11
- 2 《金工：行业配置策略：投资时钟视角》
2021.07
- 3 《金工：拥抱“高景气”还是“低估值”》
2021.09

资料来源：华泰研究

华泰金工推出中观行业景气度系列，本文为系列研究确立统一的方法学

华泰金工推出了全新的中观行业景气度系列研究。研究目的是从中观视角构建单行业景气度指数，用于预测延迟发布的 ROE_TTM 环比方向。研究思路是从产业链供需结构、内部经营状况、外部宏观环境出发，识别对单行业景气度有显著影响的指标，并通过数学模型合成景气度指数。本文作为系列研究的开篇报告，着重介绍了华泰金工自主实现的 Nowcasting 模型和自主构建的行业数据库，为系列研究确立统一的方法学。以钢铁行业为实证案例，以 ROE_TTM 为参照，结果表明 Nowcasting 模型滚动生成的中观景气度指数能够提前准确地捕捉行业真实景气度的变化方向。

Nowcasting 模型把握经济系统同源性和经济周期内生性，具备五大优势

Nowcasting 模型实时预测行业景气度，其基本假设是：1) 经济变量的同源性，即代理指标都是高维经济系统的低维映射，其变化受到系统性驱动力的作用；2) 经济周期的内生性，即经济系统的驱动力是内生的。模型包含三个方程：隐含状态方程、隐含因子状态转移方程、特质因子状态转移方程，可使用 EM 算法求解。基于隐含因子序列，可以合成实时或全局景气度指数。相较于常用指数合成方法，Nowcasting 具备五大优势：1) 内生预测景气度变化方向；2) 支持因指标发布延迟或停更的数据缺失；3) 支持混频数据；4) 支持经济含义重叠的指标；5) 建模过程不丢失指标信息。

使用生成序列开展数学实验，制定行业景气度代理指标筛选的定量标准

通过改变以下六个可能影响建模效果的维度，生成 15 万组生成序列开展数学实验：隐含因子对指标的解释度、指标序列的平稳性、指标序列数据缺失状况、选用的指标数目、截取的指标序列长度、拟合状态转移方程时选取的滞后阶数。用隐含因子复现度（拟合的隐含因子序列与生成的隐含因子序列之间的 R^2 ）评价各维度对建模效果的影响。结果表明，为了大概率获得满意解，代理指标应尽量满足以下定量标准：1) 隐含因子（行业层面可以用 ROE_TTM 代理）对指标的解释度大于 20%；2) 指标序列在 10% 显著性水平下平稳；3) 选用代理指标数目不少于 15 个。

钢铁行业中观景气度：方向预测准确率较高，单行业择时战胜上帝视角

以钢铁行业为案例，构建了包含 150 余个指标的指标库。结合定量标准和主观逻辑，筛选出 31 个景气度代理指标。在不引入未来信息的前提下，滚动生成中观景气度指数，并从两个维度评价景气度指数：1) 方向预测准确率：Nowcasting 得到的最新一期方向和下期预测方向，对 ROE_TTM 环比方向的预测准确率分别高达 82.1% 和 84.6%；2) 单行业择时效果：假设当季末能够知道该季度 ROE_TTM 变化方向，即“上帝视角”，分别使用景气度指数趋势和“上帝视角”对行业超额指数进行择时，结果显示基于景气度指数的择时业绩能够战胜“上帝视角”下的择时业绩。

风险提示：模型根据历史规律总结，历史规律可能失效。报告中涉及到的具体行业不代表任何投资意见，请投资者谨慎、理性地看待。

正文目录

本文研究导读.....	4
Nowcasting 模型介绍	7
动态因子模型：两个假设和三个方程	7
参数估计：EM 算法	9
Nowcasting：新信息与预期差	10
Nowcasting 模型的优势	11
数学实验：代理指标筛选的定量标准	12
可能影响建模效果的六个维度	12
隐含因子对指标的解释度	12
指标序列的平稳性	12
指标序列数据缺失状况	12
选用的指标数目	12
截取的指标序列长度	12
拟合状态转移方程时选取的滞后阶数	13
虚假序列生成	13
指标解释度和平稳性对建模效果的影响最大	15
案例：钢铁行业景气度指数构建与评价	18
钢铁行业产业链结构	18
景气度代理指标筛选	18
行业景气度指数构建	19
行业景气度指数评价	20
方向预测准确率	20
单行业择时效果	21
参考文献	22
风险提示	22

图表目录

图表 1: PPI:黑色金属冶炼及压延加工业与 ROE_TTM 走势对比	4
图表 2: Myspic 综合钢价指数与 ROE_TTM 走势对比	4
图表 3: 宏观-中观-微观层面分析行业景气度的逻辑链条	4
图表 4: 行业景气度指数系列研究框架	5
图表 5: 钢铁行业景气度指数与钢铁行业 ROE_TTM 对比	6
图表 6: 应用 EM 算法进行 DFM 模型参数估计	9
图表 7: Nowcasting 流程示意图	10
图表 8: Nowcasting 模型与常用的指数合成法优劣对比	11
图表 9: 数学实验考察维度及其量化指标和控制参数	13
图表 10: 平稳隐含因子序列示例 (ADF 检验 $p=0.003$)	14
图表 11: 非平稳隐含因子序列示例 (ADF 检验 $p=0.532$)	14
图表 12: 虚假序列生成及评价步骤	14
图表 13: 隐含因子对指标的解释度对建模效果的影响	15
图表 14: 指标序列的平稳性对建模效果的影响	15
图表 15: 选用的指标数目对建模效果的影响	16
图表 16: 指标序列数据缺失状况对建模效果的影响	16
图表 17: 拟合状态转移方程时选取的滞后阶数对建模效果的影响	16
图表 18: 截取的指标序列长度对建模效果的影响	16
图表 19: 满足指标筛选定量标准的生成序列建模效果统计	17
图表 20: 钢铁行业产业链结构	18
图表 21: 钢铁行业指标库详细构成	18
图表 22: 钢铁行业中观景气度代理指标	19
图表 23: 实时景气度指数与全局景气度指数示意图	19
图表 24: 钢铁行业实时景气度指数与 ROE_TTM 走势对比	20
图表 25: 钢铁行业全局景气度指数与 ROE_TTM 走势对比	20
图表 26: 景气度变化方向预测信号的两种定义	21
图表 27: 定义(1)景气度变化方向的信号命中情况	21
图表 28: 定义(2)景气度变化方向的信号命中情况	21
图表 29: 钢铁行业相对于中证全指的超额指数 (以 2011 年第一个交易日的净值归一化)	22
图表 30: 钢铁行业超额指数择时策略净值	22
图表 31: 钢铁行业超额指数择时策略业绩	22


本文研究导读

拥抱高景气行业是参与 A 股投资的主旋律之一。那么，如何识别景气度向上的行业呢？从宏观视角出发，前期报告《行业全景画像，宏观因子视角》（2020-03-26）和《行业配置策略：投资时钟视角》（2021-07-06）通过识别宏观-行业映射关系，确定了不同宏观环境下景气度相对占优的行业，并构建了行业层面的投资时钟策略。从微观视角出发，前期报告《景气度指标在行业配置中的应用》（2019-09-12）和《行业配置策略：景气度视角》（2020-11-05）使用业绩预告、业绩快报、正式财报和一致预期等数据构建了行业微观景气度打分体系，并构建了基于微观景气度的行业轮动策略。

无论是从宏观因子出发的投资时钟策略，还是基于微观景气度的行业轮动策略，都取得了不错的业绩表现。不过，我们的行业轮动框架依然存在待完善之处——缺失中观景气度这一环。前期报告《行业配置策略：景气度视角》初步尝试用行业中观层面的指标对微观景气度进行修正，取得了显著的业绩提升。下图以钢铁行业为例，展示了两个中观指标与钢铁行业 ROE_TTM 的走势，不难发现这两个指标走势与 ROE_TTM 走势高度正相关。众所周知，ROE_TTM 等微观财报指标都是按季度发布且发布存在 1 至 4 个月的延迟。中观指标也许能够在时效性方面给已有的行业轮动框架带来性能提升。


而且，无论是宏观视角还是微观视角，都是在一个统一范式中分析不同行业的景气度，中观指标与它们不同，通常带有关于单个行业独特的信息。这部分个性化信息也许能够带来信息增量，对宏观和微观视角形成有益补充。

图表1：PPI:黑色金属冶炼及压延加工业与 ROE_TTM 走势对比



资料来源：Wind, 华泰研究


图表2：Myspic 综合钢价指数与 ROE_TTM 走势对比



资料来源：Wind, 华泰研究

然而，中观指标是块“硬骨头”。首先，不同行业的产业链供需结构、内部经营状况、外部宏观环境均存在较大差异，针对不同行业，几乎无法找到一个统一范式来筛选对景气度有显著影响的中观指标。其次，中观指标来源丰富，导致其类型繁杂、口径不一、质量参差不齐，如何用这些指标去全面准确地评价行业景气度也是一个难题。

图表3：宏观-中观-微观层面分析行业景气度的逻辑链条



资料来源：华泰研究


为了打通宏观-中观-微观层面分析单行业景气度的逻辑链条，华泰金工推出了全新的研究系列——**中观行业景气度系列**。研究目的是从中观视角构建单行业景气度指数，用于预测延迟发布的 ROE_TTM 变化方向。研究思路是从产业链供需结构、内部经营状况、外部宏观环境出发，识别对单行业景气度有显著影响的指标，并通过数学模型合成景气度指数。

系列研究使用的数学模型是我们自主实现的 Nowcasting 模型。顾名思义，Nowcasting 是对尚未发布的“现在时”状态进行实时预报。对单个行业来说，当下的行业经营状况和盈利水平是客观存在的，其景气度自然已成定数，只是缺少权威机构对其进行实时发布。市场通常通过 ROE_TTM、营收同比、净利同比等微观财报指标了解行业景气度，等数据呈现在投资者面前时已经是“过去时”。而本研究想要的是“现在时”。

系列研究使用的底层数据是我们自主构建的行业指标库。对于每个行业，产业链供需结构是决定行业中观景气度的最直接因素。具体来说，行业景气度的传导路径为“下游→中游→上游”，下游商品的供需关系往是先行因素，对行业景气度有预判作用；上游原材料的供需关系往往是滞后因素，对行业景气度有确认作用。此外，行业内经营状况和行业外宏观环境也是影响行业景气度的重要因素。

系列研究最终呈现的成果是各个行业的实时景气度指数。当然，整套流程也适用于构建宏观实时景气度指数，如经济增长指数、通货膨胀指数等。


图表4： 行业景气度指数系列研究框架



资料来源：华泰研究

下图展示了通过上述方法合成的钢铁行业景气度指数，及其与 ROE_TTM 之间的对比：

图表5： 钢铁行业景气度指数与钢铁行业 ROE_TTM 对比



资料来源：Wind, 华泰研究

作为系列研究的开篇报告，本文将着重介绍行业景气度指数的构建方法，为后续研究确立统一的方法学。本文的第一部分将介绍 Nowcasting 模型的基本原理，及其相较于其他常见指数合成方法的优势；第二部分将通过数学实验，寻找模型的适用条件，为筛选合成景气度指数的代理指标提供定量依据；第三部分将以钢铁行业为例，展示从数据库构建、指标筛选、Nowcasting 建模的完整流程，并将其应用于单行业指数的择时。

Nowcasting 模型介绍

Nowcasting 模型由以下三个方程组成：

1) 隐含状态方程：

$$Y_t W_t = F_t B W_t + E_t W_t$$

2) 隐含因子状态转移方程：

$$F_t = [F_{t-1}, F_{t-2}, \dots, F_{t-p}]A + \Delta_t$$

3) 特质因子状态转移方程：

$$E_t = [E_{t-1}, E_{t-2}, \dots, E_{t-p}]H + \Phi_t$$

式中， $Y=[y_1, y_2, \dots, y_n]$ 是合成景气度指数的代理变量， W_t 是截面 t 各代理指标缺失值标记矩阵， $F=[f_1, f_2, \dots, f_r]$ 是景气度指数， $E=[e_1, e_2, \dots, e_n]$ 是各代理指标对应特质因子， B 、 A 、 H 是回归系数， Δ 和 Φ 为残差； $\{F, B, A, H\}$ 都是模型中待估计的未知量。

本部分包括四节，将依次介绍上述方程组的含义、Nowcasting 模型的优势、模型的参数估计方法、景气度指数 Nowcasting 的流程。其中，前两小节公式较为繁琐，感兴趣的读者可以选择性阅读，跳过前两小节不会影响读者对 Nowcasting 流程的理解。

动态因子模型：两个假设和三个方程

Nowcasting 的内核是动态因子模型 (Dynamic Factor Model, DFM)，其基本假设如下：

- 1) **经济变量的同源性**：代理指标 Y 都是高维经济系统的低维映射，其变化受到系统性驱动力 F （如经济增长、通货膨胀、行业景气度等）的作用；
- 2) **经济周期的内生性**：经济系统的驱动力 F 是内生的（故后文称 F 为隐含因子）。

第一个假设可表达为 Y 和 F 之间的线性映射：

$$\begin{aligned} y_1^t &= \beta_1^1 f_1^t + \beta_2^1 f_2^t + \dots + \beta_r^1 f_r^t + e_1^t \\ &\dots \\ y_n^t &= \beta_1^n f_1^t + \beta_2^n f_2^t + \dots + \beta_r^n f_r^t + e_n^t \end{aligned}$$

我们称之为**隐含状态方程**，写成矩阵形式如下：

$$Y_t = F_t B + E_t$$

式中，矩阵 B （规模 $r \times n$ ）是隐含因子载荷矩阵，矩阵 E （规模 $1 \times n$ ）的元素记录了每一个代理指标的特质部分。特质因子是各指标无法被宏观驱动力解释的部分，既包括指标统计的噪声，也包括仅来自各自所属部门的非系统性驱动力。

实际建模过程中，经常会面临指标数据发布延迟或停更的问题，例如：本月的工业增加值数据需要等到下月的中旬才能够获得。发布延迟导致存在缺失数据的截面无法进行参数估计。对此，Nowcasting 模型引入缺失值标记矩阵 W 对隐含状态方程进行修正，使得参数估计在数据缺失的情况下依然能够进行：

$$Y_t W_t = F_t B W_t + E_t W_t$$

式中，每一个截面 t 都有一个 W 矩阵。 W_t 是一个规模为 $n \times n$ 的对角阵，若指标 i 在截面 t 数据缺失， W_t 位置 (i, i) 处的取值为 0，否则为 1。

第二个假设可表达为 F 遵从 $AR(p)$ 过程：

$$\begin{aligned} f_1^t &= \alpha_1^1 f_1^{t-1} + \alpha_2^1 f_1^{t-2} + \dots + \alpha_p^1 f_1^{t-p} + \varepsilon_1^t \\ &\dots \\ f_r^t &= \alpha_1^r f_r^{t-1} + \alpha_2^r f_r^{t-2} + \dots + \alpha_p^r f_r^{t-p} + \varepsilon_r^t \end{aligned}$$

我们称之为**隐含因子状态转移方程**，亦可写成矩阵形式：

$$F_t = [F_{t-1}, F_{t-2}, \dots, F_{t-p}]A + \Delta_t$$

式中，矩阵 A 是隐含因子的状态转移矩阵，由于 F 的规模为 $1 \times r$ ，不难得到 A 的规模是 $rp \times r$ ； Δ 是经济系统运行的噪声。

海外研究(Banbura and Modugno, 2014)认为，特质因子 E 与隐含因子 F 类似，同样有规律可循。考虑到来自同一个部门的多个指标，可能受到所属部门非系统性驱动力的共同作用，所以设**特质因子状态转移方程**遵从 VAR(p)过程：

$$E_t = [E_{t-1}, E_{t-2}, \dots, E_{t-p}]H + \Phi_t$$

式中，矩阵 H 是特质因子的状态转移矩阵，由于 H 的规模为 $1 \times n$ ，不难得到 H 的规模是 $np \times n$ ； Φ 是部门运行的噪声。

现有宏观经济研究中的 Nowcasting 模型大部分基于月频时间序列进行参数估计。但代理指标不一定是月频发布。对于日频和周频指标，如资产价格指标，通过降采样能够得到月频序列；但对于季频指标，如 GDP 和行业 ROE 数据，若通过升采样获取月频序列，与隐含状态方程现有的含义不自洽，这是因为季频指标中包含了三个月的信息，而现有的隐含状态方程只用到了一个月的信息。

针对季频指标问题，已有文献都是假设 t 、 $t-1$ 、 $t-2$ 期的隐含因子、特质因子对 t 期的季频指标 Y^Q 具有相同的驱动力，并对隐含状态方程进行适当扩展：

$$Y_t^Q = \frac{1}{3}(F_t + F_{t-1} + F_{t-2})B + \frac{1}{3}(E_t + E_{t-1} + E_{t-2})$$

然而，我们在实际操作中发现，这种处理相当于在 Y_t 对 F_t 、 F_{t-1} 、 F_{t-2} 和 E_t 、 E_{t-1} 、 E_{t-2} 的回归方程中施加了三期回归系数矩阵全相等的强约束。强约束会影响参数估计的可靠性。尤其是对于国内指标，样本量本身就不大、季频指标样本量还要乘以 $1/3$ ，参数估计过程中甚至会出现估计结果趋向于无穷的情况。

对此，华泰金工另辟蹊径，不再从待估计参数入手，而是改从代理指标入手。对于月频指标 Y^M ，以 Y^M 滚动三期的均值代替原始指标；季频指标 Y^Q 保持不变。于是，滚动三期平均的月频指标拥有了和季频指标相同的三个月信息，其隐含状态方程又可以统一表达，不再存在对回归系数矩阵施加强约束的问题了。

更重要的是，对月频指标滚动三期平均的处理不会对状态转移方程产生影响：

$$\begin{aligned} F_t &= \frac{1}{3}(F_t^M + F_{t-1}^M + F_{t-2}^M) \\ &= \frac{1}{3}([F_{t-1}^M, F_{t-2}^M, \dots, F_{t-p}^M]A + [F_{t-2}^M, F_{t-3}^M, \dots, F_{t-p-1}^M]A + [F_{t-3}^M, F_{t-4}^M, \dots, F_{t-p-2}^M]A) + \Delta_t \\ &= \left[\frac{1}{3}(F_{t-1}^M + F_{t-2}^M + F_{t-3}^M), \frac{1}{3}(F_{t-2}^M + F_{t-3}^M + F_{t-4}^M), \dots, \frac{1}{3}(F_{t-p}^M + F_{t-p-1}^M + F_{t-p-2}^M) \right] A + \Delta_t \\ &= [F_{t-1}, F_{t-2}, \dots, F_{t-p}]A + \Delta_t \end{aligned}$$

相应地， F 也包含了三期信息。进一步通过下式，可以将 F 中蕴含的三期信息分离。

$$F_t^M = \begin{bmatrix} 1 & 1 & 1 & 0 & \dots & 0 & 0 & 0 \\ 0 & 1 & 1 & 1 & \dots & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 & \dots & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & \dots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 1 & 1 & 1 \end{bmatrix}_{t \times (t+2)}^+ F_t$$

参数估计：EM 算法

模型的输入是指标序列 Y ，待估计的参数包括 (F, B, A, H) 。设隐含状态方程、隐含因子状态转移方程、特质因子状态转移方程的残差，分别服从协方差矩阵为 R 、 Q_1 、 Q_2 的多元正态分布，不难写出三个方程的似然函数：

$$L_1 = \log \left[\frac{1}{\sqrt{(2\pi)^n |R|}} \sum_{t=1}^T \exp \left(-\frac{1}{2} (Y_t - F_t B - E_t) W_t R^{-1} W_t' (Y_t - F_t B - E_t)' \right) \right]$$

$$L_2 = \log \left[\frac{1}{\sqrt{(2\pi)^r |Q_1|}} \sum_{t=1}^T \exp \left(-\frac{1}{2} \Delta_t Q_1^{-1} \Delta_t' \right) \right]$$

$$L_3 = \log \left[\frac{1}{\sqrt{(2\pi)^n |Q_2|}} \sum_{t=1}^T \exp \left(-\frac{1}{2} \Phi_t Q_2^{-1} \Phi_t' \right) \right]$$

此外，注意到 F 放大 k 倍的同时 B 缩小 k 倍，对模型精度不会产生任何影响。所以， F 和 B 理论上存在无穷组解。为了提高参数估计结果的不确定性，还需要对 F 进行额外的约束，不妨设 F 的初始值服从均值为 0、协方差矩阵为单位阵的标准多元正态分布：

$$L_4 = \log \left[\frac{1}{\sqrt{(2\pi)^r}} \exp \left(-\frac{1}{2} F_0 F_0' \right) \right]$$

因此，模型的似然函数为：


$$L(F, B, A, H) = L_1(F, B) + L_2(F, A) + L_3(F, H) + L_4(F)$$

待估计参数可以通过极大似然估计求解。不过，因为似然函数各组成部分都与 F 有关，若直接对似然函数求偏导，关于各参数偏导等于 0 的方程都会带有 F ，联立求解难以得到待估计参数的解析解。那如果 F 固定呢？那么， $\{B, A, H\}$ 都将有解析解了！基于这种朴素的想法，Shumway and Stoffer(1982)提出了用 EM 算法来估计模型参数。

EM 算法的基本思想是：将全体待估计参数划分为两个子集，设定各参数初始值，然后在固定一个子集的基础上优化另一个子集，交替训练，直至似然函数收敛。子集划分的原则是：当一个子集被固定后，另一个子集的极大似然估计存在解析解。凡是满足上述子集划分原则的场景，EM 算法都是适用的。根据上述划分原则，本研究将 $\{F, B, A, H\}$ 划分为 $\{F\}$ 和 $\{B, A, H\}$ 两个子集。

EM 算法包括 Expectation 步和 Maximization 步。顾名思义，E 步在固定 $\{B, A, H\}$ 的基础上直接用 F 的最新期望值来更新 F ，M 步在固定 F 的基础上计算 $\{B, A, H\}$ 的极大似然估计。其中， F 的期望值使用卡尔曼滤波算法计算。

图表6：应用 EM 算法进行 DFM 模型参数估计



资料来源：华泰研究

受限于篇幅，本文不再赘述卡尔曼滤波的具体公式。我们通过一个通俗的例子来理解：假设有一列已出站的火车，如果想要获取火车现在的位置，有两种方法——根据上次停靠站的位置，结合车速和运行时间预测；也可以使用北斗定位系统直接测量。两种方法均存在不确定性，其结果满足不同的分布，卡尔曼滤波根据其联合分布来计算火车当前位置的期望值。回到 DFM， F 类比火车，状态转移方程对应第一种方法； Y 类比北斗定位系统，隐

含状态方程对应第二种方法。因此，F 的卡尔曼滤波结果就是用状态转移方程预测 F、用隐含状态方程反推 F，取两者联合分布的期望值。


因为 E 步和 M 步都选择当下最优的解，所以 EM 算法有可能陷入局部最优。因此，参数初始值的选取格外重要。回顾隐含因子 F 的经济学含义——多指标的系统性驱动力，不难联想到主成分分析（PCA）也能够求得对多变量具有共同解释力的因子。于是，本文使用各指标 PCA 的结果作为隐含因子 F 的初始值，并通过最小二乘法估计{B,A,H}初始值。采用统一的参数初始化方式，也有助于提升 Nowcasting 结果的可比性。

Nowcasting：新信息与预期差

第三小节将介绍 Nowcasting 的流程，尤其是要解决读者可能存在的困惑：模型使用月频序列进行参数估计，但预测结果却是实时的，这是如何做到的？答案正是在于模型不断地获取高频的新信息，并根据预期差修正预测结果，从而得到“现在时”状态。

本文以下图为例，描述每个月内通过 Nowcasting 获得隐含因子 F 实时预测值的流程。

图表7：Nowcasting 流程示意图



资料来源：华泰研究

该流程涉及四类典型的指标：

- 1) A 代表每年固定某月不发布或滞后两期发布的月频指标（如固定资产投资完成额）；
- 2) B 代表滞后一期发布的月频指标（如工业增加值）；
- 3) C 代表及时发布的月频指标（如 PMI）；
- 4) D 代表高频指标（可以是日频、周频或其他频率，如资产交易价格、利率数据）。

Nowcasting 流程如下：

- 1) t 月的第 1 天：虽然只有指标 C 有发布值，但因为隐含状态方程通过引入缺失值标记矩阵，使其在仅有一个发布值的情况下也能够完成参数估计，所以依然能够得到 F 在 t 月的拟合值，并通过隐含状态方程可以计算指标 A、B、C 在未发布月份的预测值；
- 2) t 月的第 2 天：指标 A 发布了 t-2 月值，且大于步骤(1)得到的预测值。指标 A 的超预期对 F 形成了上修的推力。对此，我们用指标 A 的最新发布值替代同期预测值，对模型参数重新进行估计，并更新指标 A、B、C 在未发布月份的预测值；

- 3) t月的第3天：指标B发布了t-1月值，且小于步骤(2)更新后的预测值。指标B的不及预期对F形成了下修的拉力。对此，我们用指标B的最新发布值替代同期预测值，对模型参数重新进行估计，并更新指标A、B、C在未发布月份的预测值；
- 4) t月的第4天：指标C发布了当月值，且恰好等于步骤(3)得到的预测值。指标D的符合预期使模型保持平衡状态，所以无需对模型进行任何修正；
- 5) t月的第5天：指标D发布了t月内的第2个取值。对于高频数据在同一个月发布的最新值，视作是对上一发布值的替代。若最新发布值大于月内的上一发布值，其效果等同于超预期，对F形成上修的推力。对此，我们用指标D最新发布值替代月内的上一发布值，对模型重新进行参数估计，并更新指标A、B在未发布月份的预测值；
- 6) t月的第X天：重复上述规则……

根据上述流程，只要某个指标发布了新的数据，就可以得到隐含因子F更新后的值。不同指标通常是错位发布的，因此F更新的日期是全体代理指标发布日期的并集，显然其频率不应低于任何一个指标。如果Y都是与经济增长相关的指标，那么作为指标Y的系统性驱动力F就可以刻画经济增长景气度；类似地，如果Y都是与单行业景气度相关的指标，那么F就是该行业的景气度指数。

Nowcasting 模型的优势

前期报告《行业配置策略：投资时钟视角》(2021-07-06)中介绍了三种常用的指数合成方法：OECD法、PCA法、扩散指数法。有读者可能会好奇：已有方法计算过程简单、结果直观明了，为什么还要构建这么复杂的Nowcasting模型？这是因为Nowcasting模型具有已有指数合成方法不具备的优势。

根据前文的介绍，Nowcasting模型能够应对缺失数据和混频数据。与OECD法和扩散指数法不同，Nowcasting模型即使使用经济含义高度重叠的多个指标，其参数估计的结果也不会受到影响。这是因为在隐含状态方程中，代理指标是因变量而非自变量。而在OECD法和扩散指数法中，使用经济含义高度重叠的多个指标去合成指数，指数的走势将会被这部分高度共线性的指标走势所左右。与PCA法和扩散指数法不同，Nowcasting模型对每个指标的特质因子部分也进行建模，所以不会丢失指标所携带的信息。而PCA法会丢弃排名靠后的主成分所携带的信息，扩散指数法会丢弃指标波幅中的信息。

最重要的是，Nowcasting模型可以对短期景气度进行迭代预测：

$$\hat{F}_{t+1} = [F_t, F_{t-1}, \dots, F_{t-p+1}]A$$

而OECD法、PCA法和扩散指数法都需依赖外生模型（如因子动量模型）对短期景气度走势进行预测。后文的行业案例将从多个维度评估Nowcasting模型的内生预测能力。

图表8：Nowcasting模型与常用的指数合成法优劣对比

考察维度	Nowcasting 模型	OECD 法	PCA 法	扩散指数法
发布延迟或停更，导致数据缺失	无影响	延迟指标滞后处理 停更指标无法使用	延迟指标滞后处理 停更指标无法使用	延迟指标滞后处理 停更指标无法使用
代理指标包含季频指标	月频指标滚动三期平均	季频指标插值+滞后处理	季频指标插值+滞后处理	季频指标插值+滞后处理
指标经济含义重叠（高度共线性）	无干扰	有干扰	无干扰	有干扰
建模过程中指标信息丢失程度	不丢失	不丢失	部分丢失	严重丢失
短期景气度的预测能力	内生预测	依赖外生模型预测	依赖外生模型预测	依赖外生模型预测
计算复杂度	复杂	一般	一般	简单

资料来源：华泰研究

数学实验：代理指标筛选的定量标准

可能影响建模效果的六个维度

根据前文的介绍，Nowcasting 模型能够在数据缺失和数据混频的情况下给出指标 Y 和隐含因子 F 的预测值。那是不是意味着只要把整个指标库“喂”给模型，模型就能够生成我们想要的景气度指数呢？答案显然是否定的。对此，本节将通过数学实验的方法，讨论模型能够大概率得到满意结果的适用条件，从而为开展指标筛选提供定量依据。

以下六个维度可能影响 Nowcasting 模型表现：

- 1) 隐含因子对指标的解释度；
- 2) 选取的指标序列的平稳性；
- 3) 指标序列数据缺失状况；
- 4) 选用的指标数目；
- 5) 截取的指标序列长度；
- 6) 拟合状态转移方程时选用的滞后阶数。

数学实验首先改变上述 6 个维度；然后，随机生成若干组虚假序列，将生成序列输入模型进行拟合；通过计算**隐含因子复现度**（拟合得到的隐含因子序列与事前生成的隐含因子序列之间的 R^2 ），来评价各维度对建模效果的影响。隐含因子复现度越高，表明满足对应条件的指标序列更容易获得满意解。

隐含因子对指标的解释度

本文使用指标对隐含因子开展单元线性回归的 R^2 来刻画隐含因子对指标的解释度。由于每一组实验涉及多个指标，考虑到解释度最低的指标可能“拖后腿”，我们最终选取**指标最小 R^2** 作为该维度的量化指标。

隐含因子对指标的解释度取决于两个参数——隐含因子载荷系数的大小和特质因子的标准差。前者刻画了指标和隐含因子之间的相关性，后者刻画了指标中无关信息的程度。前者越大，后者越小，则隐含因子对指标的解释度越高。

指标序列的平稳性

本文使用指标平稳性检验（ADF 检验）的 p 值来刻画指标序列的平稳性。 p 值越小，表明序列平稳的可能性越大。由于每一组实验涉及多个指标，考虑到最不平稳的指标可能“拖后腿”，我们最终选取**指标最大 ADF 检验 p 值**作为该维度的量化指标。指标序列的平稳性取决于两个参数——隐含因子的平稳性、特质因子的平稳性。

指标序列数据缺失状况

本文使用含缺失值指标占全体指标的比率（下文简称**缺失率**）来刻画指标序列数据缺失状况。在实际建模时，最多可能面临四期指标缺失的问题。例如，发电量指标在每年的 1 月和 2 月没有数据发布，3 月份的数据得等到 4 月中旬才发布，于是 4 月上旬就会面临 1 月至 4 月都没有数据发布的情况。

选用的指标数目

顾名思义，建模时从指标库中选用的景气度代理**指标数目**。

截取的指标序列长度

顾名思义，建模时相对于当前截面截取的代理指标**序列长度**。

拟合状态转移方程时选取的滞后阶数

实际建模时，我们无法预知隐含因子和特质因子序列的自相关阶数。那么，当拟合状态转移方程选取的滞后阶数与隐含因子、特质因子蕴含的真实自相关阶数不一致时，模型还能够得到满意解吗？对此，数学实验引入**拟合选用滞后阶数**这一维度，虽然这个维度不会影响虚假序列的生成，但有可能影响建模效果。

虚假序列生成

至此，每个维度都有了明确的控制参数和量化指标：

图表9：数学实验考察维度及其量化指标和控制参数

考察维度	量化指标	控制参数	参数取值范围
建模效果	隐含因子复现度	/	/
隐含因子对指标的解釋度	指标最小 R^2	隐含因子载荷系数 特质因子标准差	0.0 0.2 0.4 0.6 0.8 0.2 0.5 1.0 2.0 5.0
指标序列的平稳性	指标最大 ADF 检验 p 值	隐含因子平稳性 特质因子平稳性	True False True False
指标序列数据缺失状况	缺失率	缺失率	0.0 0.2 0.4 0.6 0.8
选用的指标数目	指标数目	指标数目	5 10 15 20
截取的指标序列长度	序列长度	序列长度	20 40 60 90 120
拟合状态转移方程时选取的滞后阶数	拟合选用滞后阶数	拟合选用滞后阶数	1,2,3

资料来源：华泰研究

8 个控制参数共有 30000 种组合，已经是一个不小的数目。如果再引入更多的参数，数学实验的数量将呈现指数级增长。所以我们仅用布尔型变量来描述隐含因子的平稳性和特质因子的平稳性。为了使生成的隐含因子序列尽可能接近真实的带有周期性波动的序列，我们采用以下方法生成隐含因子序列：

- 1) 若隐含因子平稳，每一个隐含因子均采用下式所示的 AR(2)模型迭代得到。采用 2 阶自相关是因为 2 阶自相关模型在一定条件¹下能够刻画经济周期。式中， Δ_t 是服从标准正态分布的随机数。

$$F_t = 0.75F_{t-1} - 0.25F_{t-2} + \Delta_t$$


- 2) 若隐含因子非平稳，每一个隐含因子均采用下式所示的正弦函数迭代得到。以 42 个月为周期是华泰周期研究系列的结论，许多宏观指标受到长度为 42 个月的基钦周期的共同驱动。式中， φ 是初相，服从 0-1 均匀分布的随机数， Δ_t 服从标准正态分布。

$$F_t = 1.5 \times \sin\left(2\pi\left(\frac{t}{42} + \varphi\right)\right) + \Delta_t$$

我们随机生成了一组平稳的隐含因子序列和一组非平稳的隐含因子序列。虽然肉眼看不出两者之间显著的差异，但是通过 ADF 检验发现，前者平稳而后者非平稳。


¹ AR(2)模型 $f_t = a_1 f_{t-1} + a_2 f_{t-2}$ 的一定条件指的是：1) 平稳性条件，即系数 a_1 和 a_2 需同时满足 $|a_2| < 1, a_1 + a_2 < 1, a_2 - a_1 < 1$ ；2) 周期性条件，即 $a_1 \times a_1 < -4a_2$ 。

图表10：平稳隐含因子序列示例（ADF 检验 $p=0.003$ ）



资料来源：华泰研究

图表11：非平稳隐含因子序列示例（ADF 检验 $p=0.532$ ）



资料来源：华泰研究

对于特质因子序列，我们仅根据 AR(2)模型平稳的条件生成虚假序列：

- 1) 若特质因子平稳，各特质因子均采用下式所示的 AR(2)模型迭代得到。式中，回归系数满足平稳性条件， φ_t 服从标准正态分布，其标准差由控制参数隐含状态方程特质因子的标准差给定。

$$E_t = 0.90E_{t-1} - 0.10E_{t-2} + \varphi_t$$


- 2) 若特质因子非平稳，各特质因子均采用下式所示的 AR(2)模型迭代得到。式中，回归系数不满足平稳性条件， φ_t 服从标准正态分布，其标准差由控制参数隐含状态方程特质因子的标准差给定。

$$E_t = 0.90E_{t-1} + 0.10E_{t-2} + \varphi_t$$

虚假序列生成包括以下几个步骤：

- 1) 给定控制参数指标数目 N ，从标准正态分布中独立随机采样，生成 1 维隐含因子和 N 维特质因子在截面 $t=0$ 和截面 $t=-1$ 的两期初始值；
- 2) 给定控制参数隐含因子平稳性、特质因子平稳性以及特质因子标准差，使用对应的迭代公式，生成相应的隐含因子序列和特质因子序列；
- 3) 给定控制参数序列长度 T ，截取截面 $t=1$ 至截面 $t=T$ 的隐含因子序列和特质因子序列；
- 4) 给定控制参数隐含因子载荷系数，将隐含因子序列乘以载荷系数，分别与 N 维特质因子序列相加，生成 N 个不带缺失值的指标序列；
- 5) 给定控制参数缺失率 η ，取前 $N \times \eta$ 个指标，针对每个被选中的指标，随机选取最近 1 至 4 期的数值并将其用缺失标记替代。

图表12：虚假序列生成及评价步骤



资料来源：华泰研究

指标解释度和平稳性对建模效果的影响最大

针对每一组控制参数组合，取不同的随机数种子重复 5 次实验，共计 15 万组数学实验。然后，对各考察维度的量化指标进行分组，统计并比较各组之间隐含因子复现度的差异，从而评价各考察维度对建模效果的影响。我们用箱线图来描述统计结果，图中箱体上下沿为四分位数，箱体内红线为中位数，箱体外红色标记指示离群样本。


隐含因子对指标的解释度和指标序列的平稳性对建模效果的影响最大。图中横轴标签的含义为“小于等于标签数值”，例如：指标最小 R^2 标签 0.2，表明该组实验样本的指标最小 R^2 都在 0.1（不含）和 0.2（含）之间。随着隐含因子对指标的解释度提升，隐含因子复现度逐步提升，当指标最小 R^2 大于 0.2 时，隐含因子复现度大概率能够在 20% 以上。随着指标序列平稳性改善，隐含因子复现度显著提升，尤其是当指标最大 ADF 检验 p 值小于等于 0.1 时，隐含因子复现度大概率能够在 70% 以上。

选用更多相关指标有助于提升建模效果。随着选用指标数目的增加，隐含因子复现度略有提升。这一结论和直觉相符——不同代理指标从不同维度提供了关于系统性驱动力的信息，相关指标越多，能够提取出来的系统性驱动力越准确。

指标缺失状况对建模效果的影响较小。当数据缺失率等于 60% 或 80% 时，尽管隐含因子复现度的 75% 分位数略有下滑，但中位数几乎不变。这说明在数据缺失的情况下，模型的预测效果并没有大打折扣，充分彰显出 Nowcasting 模型应对数据缺失的强大能力。


拟合状态转移方程时选取的滞后阶数对建模效果几乎没有影响。这对于建模工作而言是最大的一颗“定心丸”。正如前文提到，实际建模时无法预知隐含因子和特质因子序列的自相关阶数。读者难免会担忧，当拟合状态转移方程时选取的滞后阶数与隐含因子、特质因子蕴含的真实自相关阶数不一致时，模型还能够得到满意解吗？答案是肯定的！生成序列的真实自相关阶数为 2，数学实验中选用 1 阶或 3 阶自相关模型去建模，与用 2 阶自相关模型去建模的效果几乎相同。

图表13： 隐含因子对指标的解释度对建模效果的影响




资料来源：华泰研究

图表14： 指标序列的平稳性对建模效果的影响




资料来源：华泰研究

图表15： 选用的指标数目对建模效果的影响




资料来源：华泰研究

图表16： 指标序列数据缺失状况对建模效果的影响




资料来源：华泰研究

图表17： 拟合状态转移方程时选取的滞后阶数对建模效果的影响



资料来源：华泰研究

图表18： 截取的指标序列长度对建模效果的影响



资料来源：华泰研究


最后再来看截取的指标序列长度对建模效果的影响。当序列长度为 60、90、120 时，隐含因子复现度不升反降，似乎与直觉相悖。这可能是由序列非平稳性间接导致的——这三组实验隐含因子复现度的中位数均不足 10%，类似的情况也曾出现在指标最大 ADF 检验 p 值 > 0.1 的场景中。对于非平稳过程，随着序列长度增大，随机变量趋近无穷或者趋近零的程度越严重，导致模型参数估计越困难。

考虑到国内数据质量参差不齐，如果用过于苛刻的解释度和平稳性标准筛选代理指标，可能会导致代理指标数目过少。为了在解释度、平稳性和指标数目之间进行权衡，本文给出了以下代理指标筛选的定量标准：

- 1) 隐含因子对指标的解释度大于 20%；
- 2) 指标序列在 10% 显著性水平下平稳；
- 3) 选用代理指标数目不少于 15 个。

同时满足上述定量标准的生成序列约占总实验样本数的 10%。统计其隐含因子复现度，发现约 65% 的生成序列能够实现 90% 以上的隐含因子复现度，约 85% 的生成序列隐含因子复现度不低于 50%。

图表19： 满足指标筛选定量标准的生成序列建模效果统计




资料来源：华泰研究

案例：钢铁行业景气度指数构建与评价

钢铁行业产业链结构

钢铁行业使用的上游原材料主要包括铁矿石和焦炭。生产的产成品主要是粗钢和钢材，其中常见的钢材包括螺纹钢、线材、热卷、中板和冷轧。几乎各行各业都要用到钢材，最主要的应用场景有房屋、桥梁、铁路的建造以及交通工具、生产设备的制造，涉及的一级行业主要包括地产、建筑、汽车、机械等。

图表20： 钢铁行业产业链结构




资料来源：华泰研究

景气度代理指标筛选

根据梳理后的钢铁产业链结构，分别从上游原材料供需、下游商品的供需、行业内经营状况、行业外宏观环境入手，选取了 150 余个逻辑上与钢铁行业景气度存在直接联系的指标组成钢铁行业指标库。需要强调两点：

- 1) 由于研究目的是构建“现在时”的单行业景气度指数，**季频 ROE_TTM 等反映微观行业景气度的财报指标作为预测目标，不纳入指标库**；
- 2) 由于不同指标口径不一致（常见的口径包括当月值、累计值、价格、环比、同比、扩散指数、比率数据等），而且部分指标易受到季节性因素、短期噪声或长期趋势的干扰，因此还需要对不同指标有针对性地开展数据预处理工作。数据预处理用到的方法细节详见前期报告《行业配置策略：投资时钟视角》（2021-07-06）。

图表21： 钢铁行业指标库详细构成



资料来源：Wind, 华泰研究

我们遵循前文给出的代理指标定量筛选标准，对指标库进行初筛：

- 1) 隐含因子对指标的解释度大于 20%；
- 2) 指标序列在 10%显著性水平下平稳；
- 3) 选用代理指标数目不少于 15 个。

针对标准(1)，因为隐含因子无法事先获得，所以要找一个合适的代理变量。在能够反映行业景气度的财报指标（如 ROE、营收同比、净利同比）中，ROE_TTM 走势相对平稳，极端值较少，故本文选用钢铁行业 ROE_TTM 作为代理变量，并计算其对各指标的解释度。

从满足定量筛选标准的指标中，进一步选出有效数据序列较长、发布更及时、市场关注度较高、逻辑联系更为紧密的指标，共计 31 个代理指标。

为了不引入未来信息，本文采用滚动下载数据的方法：只下载给定截面能够获得的指标发布值。以铁路货运量为例，如果今天要下载 2021 年 1 月 31 日的数据，虽然 Wind 上已经有 2021 年 1 月的铁路货运量，即下载得到的指标序列到 1 月 31 日都有有效值，但事实上这个数据是 2 月 14 日才发布的，因此仍需将记录在 1 月 31 日的有效值改回缺失值。

图表22：钢铁行业中观景气度代理指标


指标名称	下载口径	指标名称	下载口径
钢铁行业采购经理人指数	扩散指数	MySpic 指数:热卷	价格
黑色金属冶炼及压延加工业:亏损企业单位数	当月值	MySpic 指数:冷板	价格
PMI:进口	扩散指数	PPI:黑色金属矿采选业:环比	环比
PMI:新出口订单	扩散指数	PPI:黑色金属冶炼及压延加工业:环比	环比
PMI:采购量	扩散指数	库存:铁矿石:港口合计	当月值
PMI:新订单	扩散指数	铁路货运量:当月值	当月值
PMI:原材料库存	扩散指数	水运货运量:当月值	当月值
PMI:生产	扩散指数	出口金额:钢材:当月值	当月值
PPI:生产资料:原材料工业:环比	环比	固定资产投资完成额:黑色金属矿采选业:累计值	累计值
PPIRM:环比	环比	MySpic 指数:国产矿:综合	价格
PPIRM:黑色金属材料类:环比	环比	进口金额:铁矿砂及其精矿:当月值	当月值
CGPI:环比	环比	进口金额:钢材:当月值	当月值
Myspic 综合钢价指数	价格	产量:挖掘机:当月值	当月值
MySpic 指数:螺纹	价格	房屋新开工面积:累计值	累计值
MySpic 指数:长材	价格	房地产开发投资完成额:累计值	累计值
MySpic 指数:线材	价格		

资料来源：Wind, 华泰研究

行业景气度指数构建

中观行业景气度指数的构建有两种思路：

图表23：实时景气度指数与全局景气度指数示意图




资料来源：华泰研究

- 1) 只看最新截面，下载截至该截面全体代理指标已发布值序列，提取成月频序列，拟合 Nowcasting 模型，将拟合得到的隐含因子序列作为景气度指数。这种思路是站在全局视角，我们称之为**全局景气度指数**。
- 2) 遍历过去每个截面，根据指标发布的延迟情况，确认截至该历史截面全体代理指标已发布值序列，提取成月频序列，拟合 Nowcasting 模型。将每个历史截面拟合得到的最后一期隐含因子值拼接，也能够得到一个景气度指数序列。这种思路是站在滚动视角，我们称之为**实时景气度指数**。


本文取 2021 年 9 月 20 日为最新截面，以周为步长，遍历自 2010 年 12 月 31 日以来的历史截面，合成钢铁行业的全局景气度指数和周频的实时景气度指数。对比景气度指数与真实 ROE_TTM 走势，不难发现两者走势较为接近，且景气度指数略微领先 ROE_TTM。因为景气度指数是当月隐含因子预测值，只含当期信息，而 ROE_TTM 是季频指标，且分子作了四季度平均，所以景气度指数的时效性更强。

图表24：钢铁行业实时景气度指数与 ROE_TTM 走势对比



资料来源：Wind, 华泰研究

图表25：钢铁行业全局景气度指数与 ROE_TTM 走势对比



资料来源：Wind, 华泰研究

以季度为窗口提取景气度指数的片段，计算其均值就得到季频景气度指数。以季频景气度指数为因变量，以 ROE_TTM 为自变量，进行线性回归。结果发现，实时景气度指数、全局景气度指数的 ROE 复现度分别高达 37%、58%。

行业景气度指数评价

除了 ROE 复现度，本文的最后一小节将从更多维度对中观行业景气度指数进行评价。

方向预测准确率

我们首先来看**方向预测准确率**——将 Nowcasting 模型滚动预测的景气度变化方向与真实 ROE_TTM 环比方向进行逐期比对，并计算命中率。前文已提及，由于 ROE_TTM 是季频指标，且分子是 12 个月净利润的平均，而滚动预测的景气度指数仅含有当月信息，具有一定领先性。为了使两者口径近似可比，以景气度指数滚动 12 个月均值的环比，即**景气度指数滚动 3 个月均值的同比**，作为 Nowcasting 模型对景气度变化方向的预测结果。

因为 Nowcasting 模型既可以得到最新一期隐含因子的拟合值，也可以得到下期隐含因子的预测值：

$$\hat{f}_{t+1} = \alpha_1 f_t + \alpha_2 f_{t-1}$$

所以景气度变化方向也有两种定义：


- 1) 最新一期方向（侧重因子动量）：

$$trend_t = \text{sign}[(f_t + f_{t-1} + f_{t-2}) - (f_{t-12} + f_{t-13} + f_{t-14})]$$

2) 下期预测方向（侧重短期预测）：

$$trend_t = \text{sign}[(\hat{f}_{t+1} + f_t + f_{t-1}) - (f_{t-11} + f_{t-12} + f_{t-13})]$$


图表26：景气度变化方向预测信号的两种定义



资料来源：华泰研究


结果显示（1代表上行，0代表下行），两种定义下景气度指数对 ROE_TTM 的方向预测准确率分别高达 82.1%和 84.6%。其中，与侧重于因子动量的定义(1)相比，侧重于短期预测的定义(2)的命中率更高，展示了 Nowcasting 模型强大的内生预测能力。

图表27：定义(1)景气度变化方向的信号命中情况



资料来源：Wind, 华泰研究

图表28：定义(2)景气度变化方向的信号命中情况



资料来源：Wind, 华泰研究


单行业择时效果

另一个维度将考察景气度指数的单行业择时效果。我们有一个大胆的设想：假如我们在当季末就已经知道该季度钢铁行业 ROE_TTM 的环比方向，若上行则买入对应的中信一级行业指数，若下行则卖出。例如，我们在 2021 年 6 月 30 日提前知道二季度 ROE_TTM 环比向上，于是整个三季度恒做多钢铁行业（事实上，二季度 ROE_TTM 于 2021 年 8 月 31 日才能获得，“上帝视角”提前了 2 个月）。那么这一“上帝视角”下的单行业择时效果就是基于 ROE_TTM 择时的“天花板”。

同时，我们使用前文预测的景气度变化方向开展相同条件下的单行业择时。如果基于景气度变化方向预测信号的择时业绩能够逼近甚至战胜上帝视角下的择时业绩，就能够进一步说明 Nowcasting 景气度指数是“过去时” ROE_TTM 一个良好的“现在时”补充。

为了消除大盘走势的干扰，我们通过做多中信钢铁行业指数、做空中证全指，构建了钢铁行业超额指数。截至本研究报告发布日，ROE_TTM 已更新至 2021Q2，回测区间选取为 2012 年 1 月 1 日至 2021 年 9 月 20 日。


图表29： 钢铁行业相对于中证全指的超额指数（以 2011 年第一个交易日的净值归一化）



资料来源：Wind, 华泰研究

回溯结果显示，定义(1)的景气度变化方向能够战胜“上帝视角”，定义(2)的景气度变化方向在信号命中、择时业绩方面几乎复刻了“上帝视角”，表明 Nowcasting 景气度指数能够提前准确地把握行业真实景气度的变化方向。

图表30： 钢铁行业超额指数择时策略净值



资料来源：Wind, 华泰研究

图表31： 钢铁行业超额指数择时策略业绩

策略名称	年化收益	最大回撤
钢铁行业超额指数	-1.52%	-53.70%
“上帝视角”	7.81%	-22.57%
最新一期方向	9.56%	-17.72%
下期预测方向	8.17%	-18.90%

资料来源：Wind, 华泰研究

参考文献

- [1] Banbura M, Modugno M. Maximum likelihood estimation of factor models on datasets with arbitrary pattern of missing data. Journal of Applied Econometrics, 2014, 29:133-160.
- [2] Shumway R H, Stoffer D S. An approach to time series smoothing and forecasting using the EM algorithm. Journal of Time Series Analysis, 1982, 3(4):253-264.

风险提示

1. 模型根据历史规律总结，历史规律可能失效。
2. 报告中涉及到的具体行业不代表任何投资意见，请投资者谨慎、理性地看待。

免责声明

分析师声明

本人，林晓明，兹证明本报告所表达的观点准确地反映了分析师对标的证券或发行人的个人意见；彼以往、现在或未来并无就其研究报告所提供的具体建议或所表达的意见直接或间接收取任何报酬。

一般声明及披露

本报告由华泰证券股份有限公司（已具备中国证监会批准的证券投资咨询业务资格，以下简称“本公司”）制作。本报告所载资料是仅供接收人的严格保密资料。本报告仅供本公司及其客户和其关联机构使用。本公司不因接收人收到本报告而视其为客户。

本报告基于本公司认为可靠的、已公开的信息编制，但本公司及其关联机构(以下统称为“华泰”)对该等信息的准确性及完整性不作任何保证。

本报告所载的意见、评估及预测仅反映报告发布当日的观点和判断。在不同时期，华泰可能会发出与本报告所载意见、评估及预测不一致的研究报告。同时，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。以往表现并不能指引未来，未来回报并不能得到保证，并存在损失本金的可能。华泰不保证本报告所含信息保持在最新状态。华泰对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本公司不是 FINRA 的注册会员，其研究分析师亦没有注册为 FINRA 的研究分析师/不具有 FINRA 分析师的注册资格。

华泰力求报告内容客观、公正，但本报告所载的观点、结论和建议仅供参考，不构成购买或出售所述证券的要约或招揽。该等观点、建议并未考虑到个别投资者的具体投资目的、财务状况以及特定需求，在任何时候均不构成对客户私人投资建议。投资者应当充分考虑自身特定状况，并完整理解和使用本报告内容，不应视本报告为做出投资决策的唯一因素。对依据或者使用本报告所造成的一切后果，华泰及作者均不承担任何法律责任。任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现，过往的业绩表现不应作为日后回报的预示。华泰不承诺也不保证任何预示的回报会得以实现，分析中所做的预测可能是基于相应的假设，任何假设的变化可能会显著影响所预测的回报。

华泰及作者在自身所知情的范围内，与本报告所指的证券或投资标的不存在法律禁止的利害关系。在法律许可的情况下，华泰可能会持有报告中提到的公司所发行的证券头寸并进行交易，为该公司提供投资银行、财务顾问或者金融产品等相关服务或向该公司招揽业务。

华泰的销售人员、交易人员或其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。华泰没有将此意见及建议向报告所有接收者进行更新的义务。华泰的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。投资者应当考虑到华泰及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。有关该方面的具体披露请参照本报告尾部。

本报告并非意图发送、发布给在当地法律或监管规则下不允许向其发送、发布的机构或人员，也并非意图发送、发布给因可得到、使用本报告的行为而使华泰违反或受制于当地法律或监管规则的机构或人员。

本报告版权仅为本公司所有。未经本公司书面许可，任何机构或个人不得以翻版、复制、发表、引用或再次分发他人(无论整份或部分)等任何形式侵犯本公司版权。如征得本公司同意进行引用、刊发的，需在允许的范围内使用，并需在使用前获取独立的法律意见，以确定该引用、刊发符合当地适用法规的要求，同时注明出处为“华泰证券研究所”，且不得对本报告进行任何有悖原意的引用、删节和修改。本公司保留追究相关责任的权利。所有本报告中使用的商标、服务标记及标记均为本公司的商标、服务标记及标记。

中国香港

本报告由华泰证券股份有限公司制作,在香港由华泰金融控股（香港）有限公司向符合《证券及期货条例》及其附属法律规定的机构投资者和专业投资者的客户进行分发。华泰金融控股（香港）有限公司受香港证券及期货事务监察委员会监管，是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。在香港获得本报告的人员若有任何有关本报告的问题,请与华泰金融控股（香港）有限公司联系。

香港-重要监管披露

- 华泰金融控股（香港）有限公司的雇员或其关联人士没有担任本报告中提及的公司或发行人的高级人员。更多信息请参见下方“美国-重要监管披露”。

美国

在美国本报告由华泰证券（美国）有限公司向符合美国监管规定的机构投资者进行发表与分发。华泰证券（美国）有限公司是美国注册经纪商和美国金融业监管局（FINRA）的注册会员。对于其在美国分发的研究报告，华泰证券（美国）有限公司根据《1934 年证券交易法》（修订版）第 15a-6 条规定以及美国证券交易委员会人员解释，对本研究报告内容负责。华泰证券（美国）有限公司联营公司的分析师不具有美国金融监管（FINRA）分析师的注册资格，可能不属于华泰证券（美国）有限公司的关联人员，因此可能不受 FINRA 关于分析师与标的公司沟通、公开露面和所持交易证券的限制。华泰证券（美国）有限公司是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。任何直接从华泰证券（美国）有限公司收到此报告并希望就本报告所述任何证券进行交易的人士，应通过华泰证券（美国）有限公司进行交易。

美国-重要监管披露

- 分析师林晓明本人及相关人士并不担任本报告所提及的标的证券或发行人的高级人员、董事或顾问。分析师及相关人士与本报告所提及的标的证券或发行人并无任何相关财务利益。本披露中所提及的“相关人士”包括 FINRA 定义下分析师的家庭成员。分析师根据华泰证券的整体收入和盈利能力获得薪酬，包括源自公司投资银行业务的收入。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或不时会以自身或代理形式向客户出售及购买华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或其高级管理层、董事和雇员可能会持有本报告中所提到的任何证券（或任何相关投资）头寸，并可能不时进行增持或减持该证券（或投资）。因此，投资者应该意识到可能存在利益冲突。

评级说明

投资评级基于分析师对报告发布日后 6 至 12 个月内行业或公司回报潜力（含此期间的股息回报）相对基准表现的预期

（A 股市场基准为沪深 300 指数，香港市场基准为恒生指数，美国市场基准为标普 500 指数），具体如下：

行业评级

增持：预计行业股票指数超越基准

中性：预计行业股票指数基本与基准持平

减持：预计行业股票指数明显弱于基准

公司评级

买入：预计股价超越基准 15%以上

增持：预计股价超越基准 5%~15%

持有：预计股价相对基准波动在-15%~5%之间

卖出：预计股价弱于基准 15%以上

暂停评级：已暂停评级、目标价及预测，以遵守适用法规及/或公司政策

无评级：股票不在常规研究覆盖范围内。投资者不应期待华泰提供该等证券及/或公司相关的持续或补充信息

法律实体披露

中国：华泰证券股份有限公司具有中国证监会核准的“证券投资咨询”业务资格，经营许可证编号为：91320000704041011J

香港：华泰金融控股（香港）有限公司具有香港证监会核准的“就证券提供意见”业务资格，经营许可证编号为：AOK809

美国：华泰证券（美国）有限公司为美国金融业监管局（FINRA）成员，具有在美国开展经纪交易商业务的资格，经营业务许可编号为：CRD#:298809/SEC#:8-70231

华泰证券股份有限公司

南京

南京市建邺区江东中路 228 号华泰证券广场 1 号楼/邮政编码：210019

电话：86 25 83389999/传真：86 25 83387521

电子邮件：ht-rd@htsc.com

深圳

深圳市福田区益田路 5999 号基金大厦 10 楼/邮政编码：518017

电话：86 755 82493932/传真：86 755 82492062

电子邮件：ht-rd@htsc.com

北京

北京市西城区太平桥大街丰盛胡同 28 号太平洋保险大厦 A 座 18 层/

邮政编码：100032

电话：86 10 63211166/传真：86 10 63211275

电子邮件：ht-rd@htsc.com

上海

上海市浦东新区东方路 18 号保利广场 E 栋 23 楼/邮政编码：200120

电话：86 21 28972098/传真：86 21 28972068

电子邮件：ht-rd@htsc.com

华泰金融控股（香港）有限公司

香港中环皇后大道中 99 号中环中心 58 楼 5808-12 室

电话：+852-3658-6000/传真：+852-2169-0770

电子邮件：research@htsc.com

http://www.htsc.com.hk

华泰证券（美国）有限公司

美国纽约哈德逊城市广场 10 号 41 楼（纽约 10001）

电话：+212-763-8160/传真：+917-725-9702

电子邮件：Huatai@htsc-us.com

http://www.htsc-us.com

©版权所有 2021 年华泰证券股份有限公司